

# Fundamentos e Introdução a Big Data

Desconstruindo paradigmas clássicos diante da volumetria, variedade e velocidade contemporâneas.

---

# Msc. Cláudio Rapôso

## Formação Acadêmica

- Doutorado em Administração — Must University
- Mestre em Administração — Must University / UNAMA
- Pós-Graduado em Big Data e Analytics — Imes
- Pós-Graduado em Banco de Dados — Imes
- Bacharel em Engenharia de Produção — Estácio de Sá
- Bacharel em Administração — UNICIV
- Tecnólogo em Análise e Desenvolvimento de Sistemas — ETEP
- Tecnólogo em Gestão de TI — UNICIV

## Certificações & Reconhecimentos



# Agenda do Curso

---

01

## Fundamentos & Big Data

Introdução aos conceitos estruturais de Big Data, desconstruindo paradigmas de dados e analisando a evolução do ecossistema de armazenamento.

02

## Paradigmas Clássicos

Problematização do armazenamento tradicional diante da volumetria extrema, variedade de formatos não estruturados e velocidade em tempo real.

03

## Limitações & Escala

Tensionamento das arquiteturas monolíticas frente à necessidade imperativa de escalabilidade distribuída exigida pela ciência de dados moderna.

---

# A Era dos Dados

Como a hiperconexão transformou dados no ativo mais valioso e  
desafiador do século XXI.

---

# O Paradigma Clássico

- Arquiteturas altamente centralizadas e de caráter monolítico.
- Forte dependência de bancos de dados relacionais e estritos (ACID).
- Escalonamento atrelado à adição de CPU e RAM no mesmo equipamento.
- Custo operacional elevado e limitação física de expansão contínua.
- Inflexibilidade no tratamento ágil de dados não estruturados.



# A Explosão Informacional

# 147 ZB

Gerados globalmente até 2024


## O Limite do Possível

O imenso volume de dados trafegados nas redes modernas ultrapassou de forma contundente a capacidade de processamento serial das arquiteturas tradicionais corporativas.

# O Paradigma Relacional (RDBMS)

Projetado para a perfeição transacional local.

- **Garantia ACID: Consistência e isolamento globais absolutos.** Cada transação é uma promessa inquebrável.
- **Schema-on-Write:** Estrutura engessada. Dados exigem validação prévia; alterações estruturais geram bloqueios e indisponibilidade.
- **Escalonamento Vertical (Scale-Up):** O limite do paradigma. Adicionar mais CPU e RAM ao mesmo servidor central.



**O Ponto de Ruptura:** Quando o custo do hardware premium supera o valor do dado, ou quando o volume excede o maior disco disponível no mercado, o modelo entra em colapso.

# Os 3 Vs do Big Data



## Volume

Escala maciça de informações.

Transição drástica de armazenamento medido em Terabytes para imensos Data Lakes em Zettabytes.



## Velocidade

Necessidade crítica de processamento e ingestão em tempo real e fluxos de streaming contínuo de alta performance.



## Variedade

Dados heterogêneos.

Capacidade de gerenciar estruturas rígidas e flexíveis: logs, textos, mídias e sensores IoT.

**Força 1: Volume  
(I/O e Armazenamento).**


A transição de Gigabytes para Petabytes esgota a capacidade física de discos locais e satura o barramento do host.

**Força 3: Variedade (Estrutura).**

Dados não estruturados e semiestruturados destroem a rigidez do mapeamento relacional clássico.

**Força 2: Velocidade  
(CPU e Rede).**

A ingestão de fluxos em tempo real (streaming) ultrapassa a capacidade de processamento de transações síncronas.



O Big Data não é apenas sobre muitos dados; é sobre o momento exato em que as leis da física computacional tornam o escalonamento vertical impossível.

# Ruptura Arquitetural

## Escalonamento Vertical (Scale-Up)

Adição progressiva de recursos de processamento e memória a um único servidor central. Atinge rapidamente o teto limite de capacidade física da máquina e resulta em custos astronômicos de hardware especializado.

## Escalonamento Horizontal (Scale-Out)

Distribuição do esforço computacional e armazenamento por meio da adição de múltiplos nós menores (commodity hardware) a um cluster. Permite escalabilidade teoricamente infinita e tolerância nativa a falhas sistêmicas.


|                       | Paradigma Relacional Clássico (RDBMS)                         | Paradigma Não Relacional (NoSQL/Big Data)                                         |
|-----------------------|---------------------------------------------------------------|-----------------------------------------------------------------------------------|
| <b>Escalabilidade</b> | Vertical ( <i>Scale-up</i> ), dependente de hardware premium. | Horizontal ( <i>Scale-out</i> ), distribuído em clusters de servidores genéricos. |
| <b>Esquema</b>        | Estrito ( <i>Schema-on-write</i> ), exige migrações custosas. | Flexível ( <i>Schema-on-read</i> ), interpretado pela aplicação.                  |
| <b>Estrutura</b>      | Altamente normalizada (evita redundância).                    | Desnormalizada (foca na localidade física e auto-suficiência).                    |
| <b>Garantias</b>      | ACID estrito (prioriza Consistência).                         | BASE / Consistência eventual ou ajustável.                                        |

O descompasso de impedância objeto-relacional forçou a engenharia a adotar novos formatos focados na leitura rápida e escalabilidade horizontal.

# Desafios Analíticos

## Complexidade Contemporânea

Em cenários de alta complexidade, a ciência de dados exige infraestruturas capazes de ingerir dados heterogêneos de redes sociais, sensores IoT e logs transacionais, processando-os com latência mínima. Uma arquitetura resiliente é vital.



# Princípio da Escalabilidade

||

Em Big Data, não levamos os dados até o poder de processamento. Nós levamos o processamento diretamente aos dados.

||


— Paradigma de Sistemas  
Distribuídos


---

# O Gargalo de Nível Micro: B-Trees e o Disco

- **Atualizações no Local** (In-place updates): Para alterar um registro, a B-Tree lê a página (8 KB), modifica em memória e reescreve na mesma posição física.
- **A Física da Falha:** Sob volumetria massiva de escrita, esse processo gera I/O aleatório extremo e divisões de página (page splits).
- **O Impacto no Hardware:** Em unidades SSD, escritas aleatórias constantes exigem ciclos de apagamento/gravação de blocos inteiros, destruindo a performance e acelerando o desgaste físico (Write Amplification).

B-Trees ( $O(\log n)$ ) são perfeitas para leitura, mas entram em colapso sob ingestão contínua e massiva de dados.





**O Truque da Física:** A ciência de dados contornou o limite do hardware transformando escritas aleatória destrutivas em anexações sequenciais (append-only), acelerando a ingestão em ordens de grandeza.

## A Solução de Escrita: LSM-Trees (Log-Structured Merge-Tree)

### Passo 1: Write-Ahead Log (WAL).

Toda escrita é primeiro anexada a um log sequencial para garantir durabilidade.

### Passo 2: Memtable.


Os dados são ordenados na memória RAM (dinâmica e ultrarrápida).

### Passo 3: SSTables Imutáveis.

Quando a Memtable enche, os dados são despejados (flushed) para o disco de forma estritamente sequencial.

# 0 Preço da Escalabilidade: 0 Trade-off da LSM-Tree


- **Amplificação de Leitura:** Como os arquivos (SSTables) são imutáveis, atualizações não sobrescrevem dados antigos. Buscar um registro pode exigir a leitura de múltiplos arquivos espalhados pelo disco.
- **Tombstones:** Exclusões são apenas marcadores adicionados ao topo; o dado real continua ocupando espaço temporariamente.



- **A Taxa de Cobrança (Compactação):** Para resolver a leitura lenta, o motor funde e limpa arquivos antigos em segundo plano. Isso gera picos massivos de uso de I/O e CPU, causando variabilidade na latência da aplicação.

# A Resposta à Variedade: O Ecossistema NoSQL

- A transição da normalização relacional forçada para a desnormalização estratégica.
- Localidade de Dados: Agrupar dados exatamente da forma como serão lidos pela aplicação (ex: documentos aninhados), eliminando junções (*joins*) de alta latência matemática.



# O Ecossistema Emergente




## 1. Ingestão

Coleta resiliente de milhares de fontes simultâneas em tempo real.



## 2. Armazenamento

Data Lakes estruturados para garantir acessibilidade, escala e governança.



## 3. Processamento

Execução rápida de análises complexas em nós computacionais paralelos.




## 0 Limite Intransponível: Teorema CAP

A lei da física das redes: Falhas de conexão (Partições – P) entre servidores vão ocorrer. É inevitável.

**Sistemas CP:** Protegem a exatidão. Rejeitam a requisição (indisponibilidade) se não puderem garantir que todos os nós têm o dado mais recente. (Ex: HBase, Zookeeper).

**Sistemas AP:** Protegem a operação. Aceitam a requisição, correndo o risco de fornecer um dado obsoleto (Consistência Eventual). (Ex: Cassandra, DynamoDB).




## PACELC: A Verdade Oculta das Operações Normais

- O Teorema CAP falha ao ignorar o sistema em estado normal. O PACELC revela o verdadeiro custo da arquitetura diária.
- O Dilema Cotidiano: Mesmo sem falhas, garantir a **Consistência (C)** exige comunicação e consenso prévio entre todos os nós do cluster, o que inevitavelmente destrói a **Latência (L)**.
- Não existe consistência forte distribuída sem pagar o imposto do **milissegundo**.

| Perfil de Carga<br>(O Problema)                | Motor Físico<br>(Nível Micro)  | Garantia<br>(Nível Macro - PACELC) | Padrão<br>Arquitetural                       |
|------------------------------------------------|--------------------------------|------------------------------------|----------------------------------------------|
| Transações Financeiras /<br>Inventário Crítico | B-Tree ou LSM<br>com Consenso  | PC/EC<br>(Consistência)            | NewSQL Distribuído<br>(Spanner, CockroachDB) |
| Ingestão IoT / Filas de<br>Streaming Massivas  | LSM-Tree Estrita               | PA/EL<br>(Latência)                | Wide-Column NoSQL<br>(Cassandra, ScyllaDB)   |
| Catálogos Flexíveis /<br>Perfis de Usuário     | B-Tree / Índices<br>Invertidos | PA/EC                              | Document NoSQL<br>(MongoDB, Couchbase)       |
| Análises Batch<br>(Petabytes)                  | Append-Only Logs               | N/A<br>(Foco em Throughput)        | DFS Moderno<br>(Colossus, S3) +<br>MapReduce |


A decisão **arquitetural** perfeita é a tradução exata do **perfil da carga** nas **leis** da **física computacional**.



A escolha da tecnologia de banco de dados não é sobre qual é melhor, mas sobre qual compromisso matemático o seu modelo de negócios suporta.


# A Camada Base: Sistemas de Arquivos Distribuídos

## O Passado: GFS / HDFS




**Gargalo** de memória no Mestre único. Custo altíssimo de armazenamento devido à **replicação física idêntica** (amplificação de **200%**).

## O Presente: Google Colossus



Metadados fragmentados (sharded), permitindo bilhões de arquivos. Substituição da replicação bruta por **Códigos de Apagamento** (Erasure Coding), reduzindo a sobrecarga para **25%-50%** enquanto tolera perdas simultâneas.

# Arquitetura Netflix



## Estudo de Caso: O Paradoxo Arquitetural da Netflix

- Sistemas de alta escala não usam uma única ferramenta. A Netflix migrou de SGBDRs clássicos para NoSQL, mas descobriu novos limites teóricos.
- A solução não foi substituir o Cassandra, mas adotar uma arquitetura híbrida.
- O Cassandra processa escritas massivas e telemetria (onde o usuário tolera dados defasados). O CockroachDB introduzido estritamente para nichos onde transações globais inquebráveis são mandatórias.

# Preparando o Terreno

A partir deste novo paradigma, os próximos passos focarão no detalhamento das arquiteturas de dados fundamentais.

01

## Armazenamento Distribuído

Foco total nas minúcias técnicas envolvidas no funcionamento interno destes sistemas robustos.

02

## Data Lakes na Realidade

Desmistificando a adoção real em cenários práticos e as estratégias viáveis de implementação.

03

## Modern Data Warehouses

Análise aprofundada sobre a robustez e a alta performance de entrega das ferramentas modernas.

# Dúvidas?

Encerramento do Encontro 01

---

# Image Sources



<https://www.skywardtel.com/wp-content/uploads/2025/09/blade-server-traditional-servers.jpg>

Source: [www.skywardtel.com](https://www.skywardtel.com)

---



[https://png.pngtree.com/thumb\\_back/fh260/background/20260628/pngtree-abstract-digital-data-tunnel-with-glowing-binary-code-and-information-flow-image\\_21964634.webp](https://png.pngtree.com/thumb_back/fh260/background/20260628/pngtree-abstract-digital-data-tunnel-with-glowing-binary-code-and-information-flow-image_21964634.webp)

Source: [pngtree.com](https://png.pngtree.com)

---



[https://media.istockphoto.com/id/2212338213/vector/abstract-glow-neon-curve-circle-for-futuristic-big-data-title-cyber-tech-with-ai-innovation.jpg?s=612x612&w=0&k=20&c=4XRZIDzmnf6SMnvHqxixH-x98sl\\_3TP4JOXomQY8LpU=](https://media.istockphoto.com/id/2212338213/vector/abstract-glow-neon-curve-circle-for-futuristic-big-data-title-cyber-tech-with-ai-innovation.jpg?s=612x612&w=0&k=20&c=4XRZIDzmnf6SMnvHqxixH-x98sl_3TP4JOXomQY8LpU=)

Source: [www.istockphoto.com](https://www.istockphoto.com)

---



[https://media.istockphoto.com/id/1714550020/vector/base-cloud-neon-lp-bl.jpg?s=612x612&w=0&k=20&c=oDYM5eMLMFWWG-9\\_lbp5keChIri06k2eWsEbiKik9us=](https://media.istockphoto.com/id/1714550020/vector/base-cloud-neon-lp-bl.jpg?s=612x612&w=0&k=20&c=oDYM5eMLMFWWG-9_lbp5keChIri06k2eWsEbiKik9us=)

Source: [www.istockphoto.com](https://www.istockphoto.com)

---



[https://static.vecteezy.com/system/resources/previews/052/896/087/non\\_2x/neon-icon-of-a-cpu-chip-processing-data-with-lines-representing-speed-vector.jpg](https://static.vecteezy.com/system/resources/previews/052/896/087/non_2x/neon-icon-of-a-cpu-chip-processing-data-with-lines-representing-speed-vector.jpg)

Source: [www.vecteezy.com](https://www.vecteezy.com)

---



[https://png.pngtree.com/thumb\\_back/fw800/background/20260112/pngtree-futuristic-blue-digital-network-grid-with-glowing-nodes-and-connections-in-image\\_21068420.webp](https://png.pngtree.com/thumb_back/fw800/background/20260112/pngtree-futuristic-blue-digital-network-grid-with-glowing-nodes-and-connections-in-image_21068420.webp)

Source: [pngtree.com](https://png.pngtree.com)

---