



Prof. MSc. Hugo Menezes Barra

Unidade Curricular: Engenharia de Dados e MLOPs

Aula 01

Apresentação do Docente

UniSENai



Prof. MSc. Hugo Menezes Barra

- Engenheiro de Controle e Automação e Mestre em Engenharia Elétrica.
- Experiência em software embarcado para multinacionais.
- AI Project Owner do Programa de Residência em Inteligência Artificial.
- Revisor do periódico IEEE Transactions on Mechatronics.

Cronograma da Unidade Curricular



Data	Entregar	Peso
10/09/2026	Trabalho I (AV1)	15%
15/10/2026	Avaliação I (AV2)	30%
___/10/2026	AIC (AV3)	10%
12/11/2026	Trabalho II (AV4)	15%
Toda a UC	Atividades Presenciais (AV5)	30%

Para TODAS as Atividades Avaliativas haverá desconto de 20% do valor da nota em caso de envios ATRASADOS.

1. Introdução da Unidade Curricular



1. Evolução dos Dados

Do BI reativo e relatórios estáticos para a Engenharia de Dados moderna e valor contínuo.



2. Papéis & Fronteiras

A sinergia entre Engenheiro de Dados, Cientista de Dados e o Engenheiro de MLOps.



3. Ciclo de Vida

Da ingestão e governança ao treinamento, deployment e monitoramento contínuo.




4. MLOps em Ação

Superando o "funciona na minha máquina" com automação, CI/CD e governança.

1.1. A Nova era de Dados

- Historicamente, as corporações armazenavam dados apenas para auditoria e relatórios mensais digitados manualmente pelo usuário.
- A Engenharia de Dados traz uma nova dinâmica na era digital pois torna-se um combustível ativo para a tomada de decisões automatizadas e inteligentes.
- A Engenharia de Dados proporciona a criação de infraestruturas resilientes em tempo real para alimentar modelos preditivos que geram impactos reais ao negócio.



1.2. Dados como Produto e em Tempo Real

- **Ingestão e Processamento de Dados:** Transição do processamento em lote para fluxos contínuos de dados (ex: Kafka e Flink) gerando insights em milissegundos.
- **Data Mesh e Data as a Product:** Dados deixam de ser um subproduto técnico e passam a ser tratados como produtos com SLAs, qualidade garantida e donos de domínio.
- **Alimentação Automatizada de ML:** Modelos preditivos e de inteligência artificial exige uma eficaz engenharia de features atualizadas em tempo real para decisões operacionais instantâneas
- **Monetização e Decisão Ativa:** A análise não se limita a explicar o que aconteceu com o BI, mas prever o que acontecerá e prescrever o que fazer.

1.3. BI Tradicional vs Engenharia Moderna

Dimensão	Business Intelligence (BI)	Engenharia de Dados & MLOps
Foco Principal	Relatórios históricos e dashboards (Análise Passada)	Pipelines automatizados e modelos de IA (Predição Contínua)
Frequência	Lotes diários, semanais ou mensais (Batch)	Tempo real, streaming e micro-batches operacionais
Arquitetura	Data Warehouse centralizado e rígido	Data Lakehouse, Lake, Feature Store e Arquitetura Distribuída
Consumidor	Executivos e Analistas Humanos	Sistemas de Decisão, Algoritmos e Produtos Digitais

2. Engenharia, Ciência de Dados e MLOPs

- A engenharia de dados garante a disponibilidade, qualidade e escalabilidade dos dados, constrói pipelines, gerencia Data Lakes e Features para consumo analítico.
- A engenharia de MLOPs faz a ponte entre a ciência e a operação, automatiza o ciclo de vida do modelo CI/CD para Machine Learning, gerencia deploy, containerização e monitora o data drift em produção.

3. Ciclo de Vida do Dado ao Modelo

UniSENAi



3. Ciclo de Vida do Dado ao Modelo

UniSENAi



4. A Crise de Machine Learning

85%

dos projetos de IA não chegam a gerar valor real em produção

Por quê MLOPs é indispensável ?

- A maior parte dos modelos de Machine Learning criados morrem em Jupyter notebooks porque falta infraestrutura automatizada, reprodutibilidade e governança.
- A MLOPs traz a cultura do DevOps para o Machine Learning, garantindo a acurácia do modelo, a segurança e atualização e evolução contínua dos dados.

5. Simulação de MLOPs

Exemplo: Simular todo o ecossistema (Dado Bruto -> Engenharia -> Treinamento -> MLOPs).

Passo 1: Criar o arquivo de configuração (config.json). O objetivo desse arquivo é simular o painel de controle do engenheiro/cientista de dados.

Passo 2: Criar o arquivo de simulação MLOPs.

6. Conclusões

- A Engenharia de Dados é a base de tudo: sem um pipeline de ETL eficiente que trate inconsistências e dados nulos, o modelo de ML falha, independentemente de quão complexo ele seja.
- A performance do modelo depende diretamente do volume, do tratamento e da qualidade do conjunto de treino — ajustar parâmetros só funciona sobre uma base sólida.
- Não basta criar um modelo bom no ambiente de testes; o MLOps automatiza logs, define critérios rígidos de aprovação (*quality gates*) e garante que apenas modelos confiáveis cheguem ao usuário final.