



Prof. MSc. Hugo Menezes Barra
Unidade Curricular: Gerência e Manutenção de Software
Aula 02

Revisão de Conteúdo



- Na aula passada, nós vimos o ecossistema geral da engenharia de dados e os conceitos iniciais de MLOPs.
- **Desafios do mundo real:** Modelos e dashboards não consomem dados brutos diretos das fontes.
- O objetivo da aula de hoje é aprender como estruturar o armazenamento para servir BI e a Inteligência Artificial.

1 – O Desafio dos Dados Operacionais **UniSENAI**

- Os bancos transacionais (OLTP) focam em registrar compras, cadastros e acessos rapidamente.
- Fazer relatórios complexos nesses bancos derruba a performance da aplicação.
- Criar um ambiente separado e otimizado para a leitura e análise de grandes volumes de dados.

2 – OLTP vs OLAP

- A **OLTP (Online Transaction Processing)** possui o objetivo de garantir alta velocidade de transação e integridade em pequenas transações.
- A estrutura utilizada é altamente normalizada (3ª Forma Normal) para evitar duplicação de dados.
- Ex: O banco de dados de um carrinho de compras de um software e-commerce.

2 – OLTP vs OLAP

- O **OLAP (Online Analytical Processing)** possui o objetivo de fazer uma leitura massiva do histórico com alta performance em agregação (**SUM, AVG**).
- A estrutura utilizada é desnormalizada para reduzir cruzamentos complexos (**JOINS**).
- Ex: O Data Warehouse que gera o dashboard do diretor de vendas.



3 – Modelagem dimensional

- A arquitetura **Star Schema (Modelo Estrela)** é um modelo que possui o objetivo de simplificar consultas SQL complexas e acelerar a velocidade de resposta.
- O **centro da estrela** é onde ficam os números, as métricas e eventos relevantes.
- As **pontas da estrela** trazem um contexto descritivo (quem, quando, onde, etc.)

3 – Modelagem dimensional

- A metodologia Ralph Kimball possui 4 passos:

Passo 1: É a fase de análise do processo.


Ex: Qual evento do mundo real queremos medir ? (Ex: Vendas.)

Passo 2: É a fase de análise da granularidade.

Ex: O que representa exatamente cada linha da tabela de fatos ?

Passos 3 & 4: Analisar as dimensões e fatos.

Ex: Quais são os contextos descritivos e quais são os números calculáveis.



3 – Modelagem dimensional

- As tabelas de dimensão possuem o objetivo de responder às perguntas: (“Quem ?”, “O quê ?”, “Onde ?” e “Quando”).
- As características desse tipo de tabela é que são ricas em texto e possuem colunas com dados desnormalizados. (ex: Cidade, Estado e Região na mesma tabela).
- Ex: dim_cliente, dim_produto, dim_tempo e dim_dispositivo.

3 – Modelagem dimensional

- As tabelas de Fatos possuem a função de armazenar eventos numéricos que aconteceram ao negócio.
- Esse tipo de tabela é composto por chaves estrangeiras (para as dimensões) + Métricas quantitativas.

Ex: Valor pago, quantidade vendida, tempo de reprodução e valor do desconto.

4 – Natural Key (NK) vs Surrogate Key (SK)

UniSENAI

- **Natural Key (NK):** O identificador que vem do sistema de origem. (ex: cliente_id da API).
- **Surrogate Key (SK):** Um chave primária sintética (inteiro sequencial) criada dentro da Data Warehouse.
- **Por que usar SK ?** Garantia de performance, desacoplamento do sistema de origem e permissão para salvar o histórico.

5 – Granularidade de Dados

- A **Granularidade** é o nível de detalhamento contido em um único registro da Tabela de Fatos.
- É melhor salvar a compra item a item do que salvar o total do dia.
- Quanto maior a granularidade (mais atômico), mais flexível é o modelo para análises futuras.

5 – Prática de Construção da DataWarehouse

- O objetivo é construir a primeira camada usando as ferramentas **Python** e **DuckDB**.
- Criem o arquivo e iremos para o VSCode realizar a simulação.

6 – Conclusões

- O mundo transacional (OLTP) é otimizado para a **operação rápida do dia a dia** em 3FN. Já o Data Warehouse (OLAP) é construído para **análises e inteligência**, reorganizando os dados no modelo dimensional (**Star Schema**) para simplificar cruzamentos e acelerar consultas.
- **Quanto mais detalhada a granularidade (nível de item), mais flexível é o seu Data Warehouse.** Salvar dados no nível atômico permite que a empresa faça qualquer tipo de agrupamento no futuro (por produto, região, horário), enquanto dados pré-agregados perdem a capacidade de responder a novas perguntas.
- O uso de **Surrogate Keys** geradas pelo próprio Data Warehouse desacopla a camada analítica dos sistemas de origem. Isso garante estabilidade ao modelo dimensional, blindando relatórios, dashboards e futuros modelos de Machine Learning contra mudanças nas regras do banco transacional.