




Prof. MSc. Hugo Menezes Barra
Unidade Curricular: Engenharia de Dados e MLOPs
Aula 03

1. Método de Classificação

- Os modelos de Inteligência Artificial podem ser do tipo de regressão (previsão contínua) e classificação (decisão categórica).
- A aplicação dependerá do mapeamento do sistema de negócio, tipo de dados e tipos de modelos (multiclasse, multirótulos ou binários).
- Transição do dado estruturado no Data Warehouse para a tomada de decisão automatizada.

1. Método de Classificação

- Classificação Binária: A detecção é feita apenas por dois rótulos. Ex: Falta e Não Falta.
- A classificação multiclasse utiliza uma série de subclassificações para rotular uma tomada de decisão. Ex: Uma falta pode ser ocasionada por queda de energia, aumento de temperatura, queda de pressão, etc.
- A complexidade das classes geram impacto no tempo de inferência e no consumo de energia.



2. O Desafio de Dados Desbalanceados

- Por que a esmagadora maioria das bases de produção é naturalmente desbalanceada.
- Riscos de treinar modelos em bases com 99% de classe majoritária e 1% de classe de interesse.
- Estratégias de amostragem na camada de preparação: *Undersampling*, *Oversampling* e SMOTE.

2. O Desafio de Dados Desbalanceados

- **Undersampling**

O que faz: Reduz o volume da **classe majoritária** (a que está em excesso) para igualar a quantidade de dados da classe minoritária.

- **Oversampling**

O que faz: Aumenta o volume da **classe minoritária** (a que está em pouca quantidade) para igualar a quantidade de dados da classe majoritária.


- **SMOTE (Synthetic Minority Over-sampling Technique)**

O que faz: Aumenta a classe minoritária de forma inteligente, criando **novos dados sintéticos** em vez de apenas duplicar os existentes.

2. O Desafio de Dados Desbalanceados

TÉCNICAS DE REAMOSTRAGEM PARA DADOS DESBALANCEADOS

● CLASSE MAJORITÁRIA ▲ CLASSE MINORITÁRIA



3. Métricas de Avaliação de Modelo

- Por que a acurácia é uma métrica enganosa em pipelines analíticos de produção.
- **Precisão vs. Recall:** O custo do Falso Positivo (inconveniência) vs. Falso Negativo (prejuízo).
- **F1-Score e ROC-AUC:** Como utilizar métricas compostas para selecionar o melhor modelo.

3. Métricas de Avaliação de Modelo

- Normalização, padronização e imputação de valores nulos em escala.
- Codificação de variáveis categóricas.
- Prevenção de *Data Leakage* (vazamento de dados) entre conjuntos de treino, validação e teste.

4. Modelos Baseados em Árvores

- Random Forest, XGBoost, LightGBM e CatBoost: os campeões para dados tabulares.
- Lidando com estruturas de dados heterogêneas e valores ausentes de forma nativa.
- Requisitos de recursos computacionais para treinamento paralelo de modelos baseados em árvores.