



Prof. MSc. Hugo Menezes Barra
Unidade Curricular: Engenharia de Dados e MLOPs
Aula 04


1. Introdução

- A digitalização de plantas fabris gera terabytes de dados operacionais que necessitam de tomada de decisão autônoma e em tempo real.
- Um exemplo de aplicação é no processo de manutenção preventiva, onde em uma linha de montagem automotiva, um classificador processa dados de sensores de vibração em braços robóticos para decidir instantaneamente se a operação deve continuar. (Classe 0 -> Operacional e Classe 1: Risco de Falha)
- No processo de controle de qualidade, as câmeras em alta velocidade classificam produtos em esteiras raras (ex: garrafas de vidro com trincas) com Aprovado ou Reprovado antes da embalagem final.

1. Introdução

- Nesse sentido, é necessário que o Engenheiro de Machine Learning domine o fluxo completo do projeto desde a etapa de tratamentos de dados até o deploy da aplicação funcional.
- Um aspecto importante é o entendimento das métricas necessárias para avaliar o modelo como acuraria, precisão, recall, curva AUC-ROC e F1-score.
- A avaliação de uma métrica de forma isolada é extremamente perigosa em sistemas críticos industriais (Ex: Detecção de falhas raras que representam apenas 0,5 % de peças produzidas).

COMPLETE MACHINE LEARNING WORKFLOW FOR INDUSTRIAL CLASSIFICATION & EVALUATION



2. Métricas de Avaliação

- Alguns conceitos fundamentais a ser explorado em métodos de classificação são:

1. **Matriz de Confusão:** É uma tabela que avalia o desempenho de um algoritmo de classificação cruzando valores reais de um problema com valores previstos pelo Modelo de Machine Learning.

MATRIZ DE CONFUSÃO (AVALIAÇÃO DE MODELOS DE CLASSIFICAÇÃO)			
		ACTUAL CLASS	
		Positive (1)	Negative (0)
PREDICTED CLASS	Positive (1)	TRUE POSITIVE (TP) ✓ CORRECTLY PREDICTED POSITIVE. The model said "Yes" and it was "Yes". 	FALSE NEGATIVE (FN) ✗ (TYPE II ERROR) INCORRECTLY PREDICTED NEGATIVE. The model said "No" but it was "Yes". (Missed Detection) 
	Negative (0)	FALSE POSITIVE (FP) ⚠ (TYPE I ERROR) INCORRECTLY PREDICTED POSITIVE. The model said "Yes" but it was "No". (False Alarm)	TRUE NEGATIVE (TN) 🛡 CORRECTLY PREDICTED NEGATIVE. The model said "No" and it was "No". 

*P=Positivo, N=Negativo

2. Métricas de Avaliação

- Aspectos dos 4 quadrantes:

1.1. Verdadeiro Positivo (TP): O evento de interesse realmente aconteceu e o modelo acertou ao prevê-lo.

1.2. Verdadeiro Negativo (TN): O evento não aconteceu (situação normal) e o modelo acertou ao dizer que estava tudo normal.

1.3. Falso Positivo (FP): O evento não aconteceu, mas o modelo disse que aconteceu.

1.4. Falso Negativo (FN): O evento aconteceu, mas o modelo disse que estava normal.

2. Métricas de Avaliação

2. Acurácia: É a proporção total de acertos (tanto de normais quanto de falhas) em relação a todas as previsões feitas.

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN}$$

Exemplo: Um modelo de detecção de falhas críticas em motores operando de maneira totalmente desbalanceada com 10 mil horas normais e apenas 50 horas de falha no dataset. Essas 50 horas representam 0,5 % de falha real.

- Se o modelo for um “chutador preguiçoso”, ele vai simplesmente dizer que tudo é normal 100 % do tempo, e consequentemente ele acertará as 9950 horas e errará as 50 horas de falha.

2. Métricas de Avaliação

- Qual será o impacto disso ?

2.1. Resultado: A acurácia do modelo é de 99,5 %.

2.2 Impacto Industrial: O modelo parece perfeito no papel, mas falhará em pegar todas as falhas reais, resultando em paradas inesperadas de operação e prejuízos milionários para a empresa.

2.3. Regra: Nunca usar a Acurácia isoladamente em dados desbalanceados.

2. Métricas de Avaliação

UniSENAi



2. Métricas de Avaliação

3. Precisão: A precisão serve para avaliar quantas vezes o modelo acertou em relação a todas as vezes que uma falha realmente ocorreu.

$$\textit{Precisão} = \frac{TP}{TP + FP}$$

- A precisão serve como uma métrica para avaliar a confiabilidade de um modelo.
- O objetivo central da precisão é minimizar falsos positivos.

2. Métricas de Avaliação

- Por exemplo, na linha de produção industrial cada alarme emitido exige parar a linha de produção e enviar uma equipe técnica altamente especializada para inspecionar o motor.
- A consequência que uma baixa precisão traz (ex: muitos alarmes falsos acionados) faz com que a equipe perca horas com inspeções desnecessárias, paralisará a produção à toa e desenvolverá a chamada “fadiga de alarme” (A equipe de manutenção passa a ignorar alertas futuros por achar que é mais um erro do sistema).

2. Métricas de Avaliação

4. Recall: É a medida de sensibilidade do sistema em relação a taxa de acerto do modelo.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- O Recall mede a capacidade de proteção do modelo e o objetivo é minimizar os falsos negativos.
- Por exemplo, se um motor falhar sem que ninguém perceba (falso negativo), ele pode explodir, causar acidentes e parar a produção por semanas.

2. Métricas de Avaliação

- Um Falso Negativo na produção custa extremamente mais caro do que enviar um técnico para checar um falso alarme. Na manutenção preditiva, o **Recall** costuma ser a métrica prioritária.

5. F1-Score e FB-Score: É a média harmônica entre Precisão e o Recall. Ela busca um equilíbrio entre a exatidão de alarmes e cobertura de falhas.

$$F1Score = 2x \frac{Precisão \times Recall}{Precisão + Recall}$$

2. Métricas de Avaliação

- Nem sempre o peso da Precisão e do Recall é igual no mundo real.
- Se o custo de perder uma falha for 10x maior que o custo de enviar um técnico sem necessidade, utiliza-se o F2-Score dando-se dobro de peso ao Recall.
- Se a checagem for extremamente cara e interromper o faturamento da empresa, utiliza-se o F0,5-Score, dando mais peso a precisão.

2. Métricas de Avaliação

6. Curva AUC-ROC: Os modelos de Machine Learning não escolhem apenas 0 e 1 direto, eles retornam uma probabilidade (ex: 80 % de chance de falha). Por padrão, qualquer valor acima de 50 % é considerado falha.

- A curva ROC plota a taxa de verdadeiros positivos (Recall) contra a Taxa de Falsos Positivos (1 – Especificidade) conforme variamos esse limite (threshold) de 0 à 100 %.
- A AUC é um número único entre 0.5 e 1.0 que resume a capacidade geral do modelo de separar classes.

2. Métricas de Avaliação

- A AUC-ROC permite avaliar se o modelo é intrinsecamente bom **antes de decidir o limite de corte financeiro.**

Otimização de Operação: Se o motor estiver rodando em uma época de demanda máxima (onde parar custa muito caro), o engenheiro pode subir o *threshold* para 80% (priorizando Precisão). Se for uma época de manutenção preventiva programada, o engenheiro baixa o *threshold* para 30% (priorizando Recall). A AUC mede se o algoritmo sustenta essa flexibilidade.

3. Conclusões

- Em sistemas críticos e desbalanceados da Indústria 4.0, a acurácia mascara o fracasso do modelo em identificar eventos raros; confiar nela pode custar milhões em paradas não planejadas.
- A escolha do indicador principal (Recall vs. Precisão) deve ser guiada pelo impacto financeiro da operação — priorizando o Recall quando o Falso Negativo (falha oculta) for infinitamente mais custoso que um alarme falso.
- Mais do que números, a matriz de confusão decompõe a natureza do erro, permitindo ao engenheiro calibrar limiares (*thresholds*) e tomar decisões estratégicas com base na Curva AUC-ROC.
- A validação de métricas só é confiável se os dados de teste forem completamente isolados antes do pré-processamento, estruturando o pipeline para garantir reprodutibilidade e estabilidade no deploy em produção.