



Prof. MSc. Hugo Menezes Barra
Unidade Curricular: Engenharia de Dados e MLOPs
Aula 05

1. Arquitetura de Dados e ETL

- A arquitetura de dados sólida transforma dados brutos em ativos estratégicos através dos seguintes pilares:
 1. **Modelagem e Armazenamento:** A organização dos dados em estruturas adequadas (bancos relacionais, NoSQL, Data Lakes e Data Lakehouses) alinhados ao volume de uso pretendido.
 2. **Ingestão e Pipelines (ETL):** Criação de fluxos automatizados para extrair, transformar e carregar dados de diferentes fontes, operando em lote ou em tempo real.
 3. **Governança e Qualidade:** Políticas de governança para definir o catálogo de dados, a padronização, a linhagem e as regras de consistência da origem ao destino.

1. Arquitetura de Dados e ETL


UniSENAi

4. Segurança e Conformidade: Mecanismos de criptografia, controle de acesso e conformidade legal com regulamentações de privacidade como a LGPD.

5. Escalabilidade e Desempenho: Infraestrutura projetada para crescer de forma elástica conforme o aumento do volume de dados, garantindo respostas rápidas e otimizações de custos.

6. Democratização e Consumo: Disponibilização eficiente dos dados para usuários de negócio, ferramentas de BI, integrações via APIs e modelos de Machine Learning.

1. Arquitetura de Dados e ETL



2. Automação e Práticas de ETL

- Utilização de ferramentas que geram a documentação diretamente do código ou dos pipelines (como o dbt), garantindo que os esquemas, descrições e linhagens fiquem sempre atualizados sem esforço manual.
- Registrar de forma clara e visual o caminho completo dos dados desde a origem da extração, passando pelas regras de transformação até o destino final (facilitando a rastreabilidade e análise de impacto).
- Manter um repositório centralizado detalhando o significado de cada campo, o tipo de dado, as convenções de nomenclatura e a lógica por trás de cada cálculo aplicado.

2. Automação e Práticas de ETL

- Documentar os comportamentos esperados do sistema, os códigos de erros comuns, os fluxos de exceção e os procedimentos operacionais padrão (SOPs) para resolução de falhas nas rotinas do ETL.
- Incluir na documentação a especificação de todos os testes automatizados (como checagem de nulls, unicidade, integridade referencial e limites), deixando transparente o padrão de qualidade exigido.
- Armazenar a documentação junto ao repositório de código (como arquivos Markdown) ou em plataformas de governança integradas , versionando as regras de negócio junto com as atualizações das rotinas de ETL

3. O Papel da Documentação de Dados

Documentação Tradicional

Manuais estáticos, planilhas desatualizadas e Wikis mantidas manualmente.

Gera alto débito técnico, silos de conhecimento e perda de confiabilidade nas regras de negócio com a evolução rápida dos sistemas.

Documentação Viva (Data-Driven)

Extraída automaticamente de bancos de dados, scripts ETL e pipelines CI/CD.

Garante alinhamento em tempo real com a produção, rastreabilidade técnica (Data Lineage) e transparência para toda a organização.

3. O Papel da Documentação de Dados



3. O Papel da Documentação de Dados

- **Fontes de Dados:** É o ponto de origem onde os dados são extraídos.

Ex: Bancos de Dados Relacionais (MySQL e PostgreSQL), APIs REST, arquivos de logs, sistemas ERPs ou planilhas.

Obs: Essa é a primeira etapa do fluxo, onde o dado ainda está no seu formato original de produção.

3. O Papel da Documentação de Dados

- **Ingestão Offline (Processamento em Lote):** É captura agendada e periódica dos dados (a cada hora, diariamente, semanalmente, etc.)

Ex: Ferramentas comuns como Python (Pandas), AWS Glue e Azure Data Factory.

Obs: Essas ferramentas são utilizadas quando o volume de dados é alto e o negócio não necessita de atualizações a cada milissegundos para tomar decisões.

3. O Papel da Documentação de Dados

Armazenamento Bruto (Camada Bronze / Staging Area)

- A zona de pouso inicial do Data Lake ou Lakehouse onde os dados de origem são gravados exatamente como foram extraídos.
- Armazena o histórico original (*raw data*) sem aplicar nenhuma regra de negócio ou limpeza pesada, mantendo fidelidade total à origem (formatos como CSV, JSON ou dumps SQL).
- Garante auditabilidade e permite reprocessar os dados do zero caso ocorra alguma falha posterior no pipeline.

3. O Papel da Documentação de Dados

Armazenamento Bruto (Camada Bronze / Staging Area)

- A zona de pouso inicial do Data Lake/Lakehouse onde os dados de origem são gravados exatamente como foram extraídos.
- Armazena o histórico cru (*raw data*) sem aplicar nenhuma regra de negócio ou limpeza pesada, mantendo fidelidade total à origem (formatos como CSV, JSON ou dumps SQL).
- Garante auditabilidade e permite reprocessar os dados do zero caso ocorra alguma falha posterior no pipeline.

4. Processo de Transformação, Compactação e Otimização

- **O que é:** O motor que limpa, padroniza e reestrutura os dados brutos da camada Bronze para torná-los eficientes em consultas.
- **Conversão de Formato:** Transforma arquivos de texto simples (CSV/JSON) em formatos **colunares** (como **Parquet** ou **ORC**), que leem apenas as colunas necessárias durante uma consulta, reduzindo custos de I/O.
- **Compressão de Dados:** Aplica algoritmos de compressão (como **Snappy** ou **Gzip**) diretamente nos arquivos colunares para reduzir drasticamente o uso de disco e acelerar a transferência pela rede.
- **Onde se aplica:** É a ponte entre a camada Bronze (bruta) e as camadas refinadas (Prata/Ouro).

4. Processo de Transformação, Compactação e Otimização

- **Camada Prata (Silver):** Dados limpos, deduplicados, com tipos de dados corrigidos e enriquecidos. Pronta para análises exploratórias e engenharia de dados.
- **Camada Ouro (Gold):** Dados agregados, modelados em esquemas analíticos (como Star Schema ou Snowflake) com regras de negócio finais aplicadas.
- **Onde se aplica:** Alimentação de relatórios de BI (Power BI, Tableau), dashboards executivos e modelos de Machine Learning.

5. Trechos Chave de Código

- **Extração/Leitura:** Apresentar e descrever o trecho de código responsável por ler e validar a fonte de dados offline.
- **Transformação e Limpeza:** Destacar a lógica principal de negócio (tratamento de valores nulos, deduplicação, cast de tipos e criação de colunas calculadas).
- **Escrita e Otimização:** Exibir o código responsável pela gravação final em formato compactado e particionado (ex.: `.write.parquet()` ou salvando em camadas do Lakehouse).
- **Explicação Textual:** Para cada trecho de código colado, adicionar uma breve explicação descritiva do **porquê** e do **como** aquela instrução opera no pipeline.

6. Volumetria e Otimização de Dados

- **Tamanho do Arquivo Bruto:** Registrar o volume/tamanho original dos dados antes do processamento (ex.: 5 GB em CSV).
- **Tamanho do Arquivo Final Otimizado:** Informar a volumetria obtida após a transformação e compactação (ex.: 850 MB em Parquet).
- **Métricas de Eficiência:** Apresentar a taxa/percentual de redução de espaço e a justificativa técnica (ex.: redução de 83% obtida pela compressão colunar Snappy).