




Prof. MSc. Hugo Menezes Barra

Unidade Curricular: Engenharia de Dados e MLOPs

Aula 06

1. Ingestão de Dados

- É o processo de obter e importar dados de diversas fontes para um repositório central (Data Lake ou Warehouse).
- ✓ Coleta de dados brutos (Raw Data).
- ✓ Movimentação eficiente entre camadas.
- ✓ Ponto de entrada fundamental para Analytics.

UniSENAI

2. Batch vs Streaming

- Por quê usar lotes (Batch) ?
 - Processamento periódico em grandes janelas de tempo.

Custo: Mais barato do que processamento em real-time.

Volume: Ideal para gigabytes de dados históricos.

Simplicidade: Orquestração e debug facilitados.

2. Batch vs Streaming

- As principais vantagens são:



Eficiência

Otimiza o uso de recursos computacionais durante horários de baixo pico.



Consistência

Garante que grandes volumes de dados sejam validados de forma integral.



Confiabilidade

Processos de checkpoint e re-processamento são nativos em Batch.

3. Arquitetura e Fluxo

ELT (Extract-Load-Transform)

- É o padrão dominante na nuvem moderna.
- Os dados são carregados de maneira bruta (“raw”) no Data Lake.
- A transformação ocorre usando o poder do Cloud Warehouse.
- Maior agilidade para que analistas de dados tomem decisões.



3. Arquitetura e Fluxo

A arquitetura Medalhão

- **Camada Bronze:** Dados brutos e imutáveis.
- **Camada Prata:** Dados limpos, filtrados e padronizados.
- **Camada Ouro:** Dados agregados e prontos para o negócio.

4. Extração Total vs Incremental

Full Load: Copia todo o conjunto de dados da fonte. Simples, mas ineficiente para grandes volumes.

Incremental Load: Busca apenas os registros novos ou atualizados desde a última execução.

4. Extração Total, Incremental e Colunar

Full Load: Copia todo o conjunto de dados da fonte. Simples, mas ineficiente para grandes volumes.

Incremental Load: Busca apenas os registros novos ou atualizados desde a última execução.

Formatos Colunares: Formatos de arquivo projetados especificamente para engenharia de dados. Diferente de um CSV ou JSON (que organizam dados por linhas), os formatos colunares organizam por colunas. Isso permite ler apenas as colunas necessárias para uma consulta, compactando o arquivo e acelerando o processamento drasticamente.

5. Tecnologias Core

- **Apache Spark:** O motor de processamento distribuído mais utilizado no mundo para Big Data. Ele divide grandes volumes de dados em vários nós (máquinas) para processá-los em memória e em paralelo.
- **Apache Airflow:** Uma ferramenta de **orquestração** de pipelines. Ela permite agendar, monitorar e gerenciar a ordem de execução de tarefas (ex: "Execute o script A às 02h; se der certo, execute o script B; se falhar, envie um e-mail de alerta").
- **dbt (data build tool):** Ferramenta focada na etapa de **Transformação** dentro do padrão ELT. Permite que engenheiros e analistas escrevam transformações de dados usando código SQL simples, cuidando automaticamente da criação de tabelas, testes e documentação.

6. Engenharia de Qualidade

- **Particionamento:** Técnica de divisão física dos arquivos de dados em pastas lógicas com base em uma coluna (ex: ano=2026/mes=09/dia=03/). Isso evita ter que ler terabytes de dados quando uma consulta precisa apenas dos dados de hoje.
- **Idempotência:** Propriedade de um pipeline que garante que **executar o mesmo lote 1 ou 100 vezes produzirá exatamente o mesmo resultado**, sem duplicar registros ou corromper a base.
- **Resiliência e Mecanismos de Retry:** A capacidade do pipeline de lidar com falhas temporárias (como uma oscilação na rede ou indisponibilidade de uma API) através de novas tentativas automáticas (retries) antes de abortar a execução.
- **Observabilidade de Dados:** Prática de monitorar a "saúde" do sistema e dos dados ao longo do pipeline (métricas de tempo de execução, volume de linhas ingeridas, presença de campos nulos, alertas de anomalias).

6. Engenharia de Qualidade



Não basta o pipeline rodar, os dados precisam estar corretos.

- **Freshness:** Os dados estão atualizados ?
- **Volume:** Houve queda brusca na ingestão ?
- **Schema:** A estrutura da fonte mudou ?

7. Práticas, Governança e Custos

- **LGPD (Lei Geral de Proteção de Dados):** Exige que o pipeline garanta o tratamento adequado de dados pessoais, como a **anonimização** (mascarar CPF, nomes) e mecanismos para remover dados de usuários se solicitado (direito ao esquecimento).
- **FinOps (Financial Operations):** Cultura de gestão financeira para nuvem. Na engenharia de dados, envolve otimizar o uso de recursos (ex: desligar clusters após a execução, escolher o tipo certo de instância, usar arquivos compactados) para evitar contas exorbitantes.
- **Catálogo de Dados (Data Catalog):** Um inventário detalhado de todos os dados da empresa. Funciona como um "Google interno" onde os usuários e engenheiros buscam onde determinada tabela está, quem é o dono, qual sua origem e o que cada coluna significa.

8. Tendências Futuras

Zero-ETL

Abordagem emergente que visa eliminar a necessidade de criar pipelines complexos de ETL/ELT entre bancos de dados e Data Warehouses, permitindo a integração direta e quase instantânea fornecida pelos próprios provedores de nuvem.